Discussione della relazione finale

Applicazione di modelli di classificazione per la valutazione delle prestazioni nel calcio: gli Expected Goals e gli Expected Points

Varotto Luca

UNIVERSITÀ DEGLI STUDI DI PADOVA
STATISTICA PER LE TECNOLOGIE E LE SCIENZE
ANNO ACCADEMICO 2023/2024

Relatrice Prof.ssa Cattelan
Controrelatore Prof. Bernardi



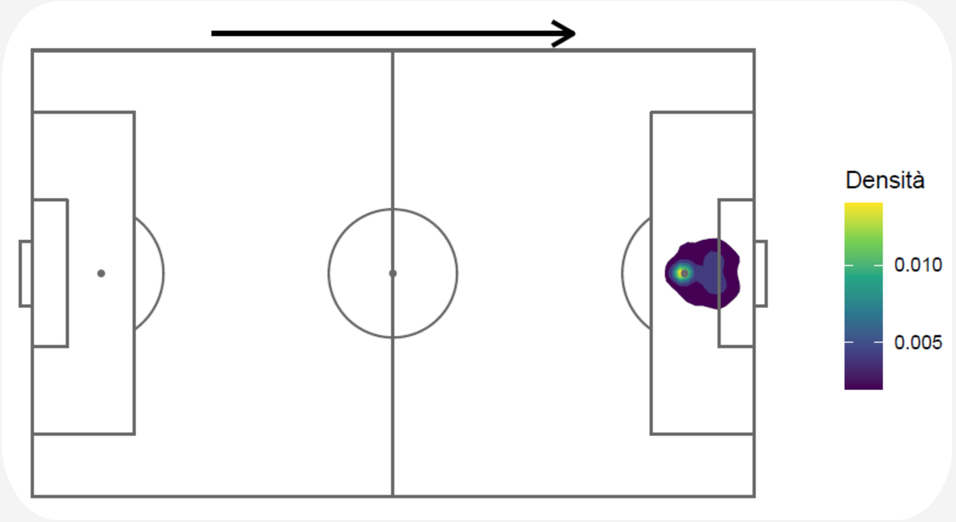
Introduzione

- Obbietivo della relazione.
- Il concetto di Expected Goals.
- L’origine in letteratura e le prime applicazioni nel mondo del calcio.

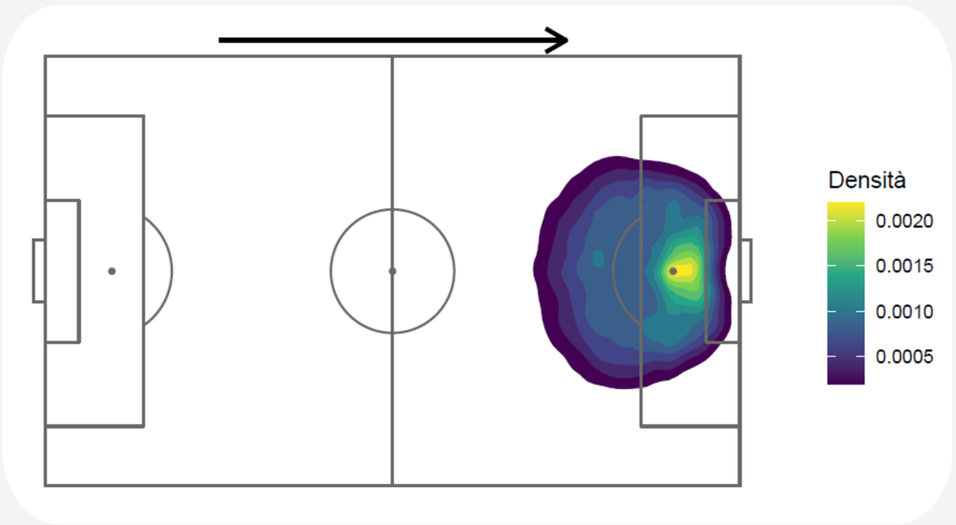
Il dataset

Aspetti cruciali

- Il numero di campionati necessari per stimare un buon modello.
- Il numero sbilanciato di successi ed insuccessi.
- Le tecniche di bilanciamento del dataset utilizzato.



Densità dei tiri risultati in goal, stimata con il metodo del nucleo..



Densità dei tiri non risultati in goal, stimata con il metodo del nucleo..

Le metriche di valutazione dei modelli

La scelta della soglia partendo dalla curva ROC.

- L’angolo in alto a sinistra della curva ROC rappresenta il modello perfetto.

La scelta dell’F-score come metrica di valutazione.

- L’F-score si calcola a partire dalla precisione e dalla sensibilità.

I modelli usati

Logistica con solo distanza e angolo di tiro	• Si è rivelato utile per quantificare l'effetto della distanza e dell'angolo di tiro.
Logistica forward	• Si è rivelato il miglior modello.
Logistica con penalità Lasso	• Si è rivelato utile per effettuare una selezione delle modalità dei fattori a più livelli.
Logistica con penalità Grouped Lasso	• Ha confermato la significatività di tutti i fattori a più livelli.
Alberi di classificazione	• Hanno fornito un'interpretazione dell'importanza delle variabili.
Random Forest	• Hanno fornito un'ulteriore intepretazione dell'importanza delle variabili.

Il miglior modello: la regressione logistica con approccio forward

- **Stimato sui dati bilanciati con SMOTE-NC.**
- **AUC: 0.815.**
- **Soglia: 0.188.**
- **F-score: 0.424.**
- **Specificità: 0.900.**
- **Sensibiltà: 0.526.**
- **Accuratezza: 0.864.**

Due applicazioni alla valutazione delle prestazioni

Analisi di una singola partita

Elenca i suggerimenti che risponderanno alle problematiche emerse dalla ricerca.

Gli Expected Points

Riflettono il numero medio di punti che una squadra otterrebbe se la partita si giocasse un numero elevato di volte.

I limiti del modello

La natura del calcistica del gol

- Non tutte le occasioni da gol si concretizzano in tiri e non tutti i gol seguono a dei tiri.

Il problema della raccolta dei dati

- Le posizioni dei tiri sono rilevate a mano.
- I campi d.i calcio hanno dimensioni variabili.

Il limite dei dati

- I valori mancanti.
- Mancanza di variabili più complesse come l’altezza da cui è stato effettuato il tiro.

L’assunto di indipendenza

- Risolvibile introducendo varibili relative allo stato di forma dei calciatori e delle squadre o un fattore temporale.

Possibili sviluppi

Alternative ai modelli presentati

- Applicazione di un approccio di boosting agli alberi di classificazione.

Ulteriori approcci

- Analisi delle immagini del momento in cui viene effettuato il tiro.

Bibliografia

- Pollard, Richard, and Charles Reep. "Measuring the effectiveness of playing strategies at soccer." Journal of the Royal Statistical Society Series D: The Statistician 46.4 (1997): 541-550.
- Umami, Izzatul, Deden Hardan Gautama, and Heliza Rahmania Hatta. "Implementing the Expected Goal (xG) model to predict scores in soccer matches." International Journal of Informatics and Information Systems 4.1 (2021): 38-54.
- Hastie, Trevor, et al. “The elements of statistical learning: data mining, inference, and prediction”. Vol. 2. New York: Springer, 2009.
- Breiman, Leo. "Random forests." Machine learning 45 (2001): 5-32.

Grazie per l’attenzione